

תרגול - DWH, ETL, STTM

תרחיש

חברת מסחר רב-ערוצית מפעילה אתר e-commerce, אפליקציה סלולרית ורשת חנויות פיזיות. עם השנים הנתונים התפעוליים התפזרו בין כמה מערכות, וכל מערכת משקפת היבט אחר של הפעילות העסקית:

- orders_src ו-order_items_src מגיעות ממערכת Order Management / POS שאוספת הזמנות מהאתר, מהאפליקציה ומהקופות. שורות ההזמנה כוללות גם פרטי מוצר בסיסיים כמו שם מוצר וקטגוריה.
 - customers_src מגיעה ממערכת CRM שבה מנוהלים פרטי הלקוח, הסגמנט והשייכות הגאוגרפית.
 - returns_src מגיעה ממערכת שירות והחזרות נפרדת, שמתעדכנת לעיתים באיחור ביחס להזמנה המקורית.
- ההנהלה מבקשת דשבורדים אמינים עבור:
- הכנסה נטו יומית לפי אזור וקטגוריית מוצר
 - שיעור מימוש הזמנות שבועי לפי ערוץ
 - ביצועי סגמנטים של לקוחות ברמה חודשית
- לצורך התרגול, השתמשו בהגדרות העבודה הבאות:
- הכנסה ברוטו (gross_revenue) - סכום $quantity * unit_price$ לפני הנחות והחזרות.
 - הכנסה נטו (net_revenue) - מחושבת ע"י $gross_revenue - discount_amount - return_amount$.
 - שיעור מימוש הזמנות - היחס בין הזמנות שהסטטוס האחרון שלהן הוא completed לבין כלל ההזמנות.
 - אם בחרתם כלל עסקי אחר לייחוס החזרות או להגדרת KPI, ציינו אותו במפורש.

המערכות אינן תמיד עקביות, וחלק מהעדכונים מגיעים באיחור. אותו לקוח או אותו עסקי עשויים להופיע בפורמטים שונים בין המערכות. לדוגמה, מערכת ההזמנות יכולה לשמור 'customer_ref=orp' בעוד מערכת הCRM שומרת 'customer_ref=user_orp'. גם הערכים של channel, segment, category ו-region אינם תמיד אחידים.

חלק א - היכרות עם מקורות הנתונים

1. הריצו את sources.sql וצרו את טבלאות המקור.
2. סקרו את הנתונים והבינו את הערכים שיש בכל אחד מן המקורות.
3. צרו סכמת staging ובצעו מיפוי של כל המקורות אל הסכמה.
4. ב-staging, צרו views (כמה שנדרש) שמטרתם להגדיר את לוגיקה/חוקים להמיר את המקורות למבנה מבוקר עבור DWH.

חלק ב - מידול DWH ו-ETL ראשוני

1. תכננו את ארכיטקטורת DWH - סכמה, טבלת fact, ממדים נדרשים.
2. צרו את סכמת ה-DWH עפ"י התכנון מסעיף קודם.
3. הגדירו את שלבי Extract, Transform, Load (לא בקוד, אלא מה יתבצע בכל שלב).
4. הוסיפו טבלה שנקראית etl_run_log אשר מתעדת את היסטוריית הרצת ETL.

חלק ג - טעינה אינקרמנטלית ו-STTM

הערות: התהליך רץ בכל יום בשעה קבועה (אחת ל-24 שעות), הרצה חוזרת חייבת להיות idempotent.

1. מלאו מיפוי STTM עבור 4-5 שדות יעד לפחות.
2. ממשו את תהליך ה-ETL לאיחסון **הממדים** השונים. יש לקחת בחשבון טעינה אינקרמנטלית.
3. ממשו את תהליך ה-ETL לאיחסון טבלת **fact**. יש לקחת בחשבון טעינה אינקרמנטלית.
4. הסבירו כיצד צריך לטפל ברשומות מאוחרות המגיעות מ-returns_src.

תבנית STTM

target_table	target_column	source_column	transform_rule	key_type	null_policy

חלק ד - שאלות אנליטיות וביצועים

כתבו SQL עם window functions עבור:

1. הכנסה נטו יומית לפי אזור וקטגוריה, כולל סכום מצטבר לכל אזור וקטגוריה לאורך זמן.
2. שיעור מימוש הזמנות שבועי לפי ערוץ קנוני, כולל דירוג הערוצים בכל שבוע לפי שיעור המימוש.
3. הכנסה נטו חודשית לפי סגמנט לקוח, כולל הכנסה בחודש הקודם ושינוי מחודש לחודש.
4. חמשת המוצרים המובילים לפי הכנסה נטו ב-30 הימים האחרונים.